

Observatório CISEB

Esqueleto Arquitetural — Imersões em Trilhas de Aprendizagem

Sistema de monitoramento em tempo real de web, GitHub, fóruns, redes sociais, literatura acadêmica e eventos/editais. Curadoria por IA com revisão humana, entrega via newsletter semanal e alertas instantâneos, organizada pelos seis pilares CISEB.

PREPARADO POR

Núcleo de Inovação CISEB

DATA

Junho de 2026 · v1.0

Sumário

Capítulo 1 — Sumário Executivo	3
Princípios de desenho	3
Capítulo 2 — Contexto, Justificativa e os 6 Pilares CISEB	4
Os seis pilares em detalhe	4
A lacuna que o Observatório preenche	5
Capítulo 3 — Domínio Semântico: O Que Conta como Achado	6
Capítulo 4 — Visão Arquitetural Macro	7
Princípios arquiteturais	7
Capítulo 5 — Camada de Coletores: As 6 Fontes	8
Considerações sobre ToS e ética de coleta	9
Capítulo 6 — Ingestão, Fila e Normalização	9
Schema de evento	9
Deduplicação e normalização	10
Capítulo 7 — Classificação por Pilar CISEB e Scoring de Relevância	10
Classificador multi-rótulo por pilar	10
Fórmula de scoring composto	11
Thresholds de roteamento	11
Capítulo 8 — Armazenamento e Busca Semântica	12
Esquema principal	12
Índices e estratégia de busca	12
Capítulo 9 — Curadoria IA + Revisão Humana	13
Pipeline de curadoria	13
Interface de revisão	13
Feedback loop e recalibração	14
Capítulo 10 — Camada de Entrega: Newsletter e Alertas	14
Alertas instantâneos	14
Newsletter semanal	14
Dashboard web (opcional, Fase 3)	15
Capítulo 11 — Fluxo de Comunicação, Papéis e SLA	15
Tabela de SLAs	15

Tratamento de exceções	16
Capítulo 12 — Stack Tecnológica Sugerida	16
Capítulo 13 — Roadmap de Implementação	18
Capítulo 14 — Governança, Ética e Riscos	19
Princípios éticos operacionais	19
Capítulo 15 — Métricas de Sucesso (KPIs)	20
Capítulo 16 — Próximos Passos e Decisões Pendentes	21

Capítulo 1 — Sumário Executivo

Este documento apresenta o esqueleto arquitetural do **Observatório CISEB**, um sistema de monitoramento em tempo real projetado para capturar, curar e entregar à equipe do CISEB notícias, projetos, repositórios, artigos e oportunidades relacionadas às **Imersões em Trilhas de Aprendizagem** e aos seis pilares de atuação do Centro: Inteligência Artificial, Cultura Maker, Cultura Digital (Realidade Virtual e Aumentada), Tecnologia e Arte, Fabricação Digital e Robótica Educacional. O desenho aqui proposto combina a visão de **Orquestrador** — responsável pelo fluxo de comunicação, papéis e SLAs — com a visão de **Arquiteto** — responsável pelos componentes técnicos, pipelines e escolha de stack.

A motivação central é resolver a fragmentação informacional que hoje obriga a equipe a buscar manualmente em dezenas de portais, redes sociais e repositórios. O Observatório automatiza a coleta contínua em seis grandes famílias de fontes, submete o material a um pipeline de classificação por pilar CISEB e scoring de relevância, e entrega o resultado em dois canais complementares: **alertas instantâneos** via Telegram e WhatsApp para achados de alto valor, e uma **newsletter semanal** curada em PDF para o acompanhamento consolidado. Toda a curadoria é feita por IA, com um revisor humano aprovando o top-N diário antes da publicação — modelo que chamamos de IA full + revisão.

O documento responde, em ordem, às quatro perguntas que orientaram sua encomenda: **o que precisa ser feito** (capítulos 4 a 9 — arquitetura e camadas técnicas), **como será feito** (capítulos 5 a 13 — componentes, stack e roadmap), **como será o resultado** (capítulos 10, 15 e 16 — entrega, KPIs e próximos passos) e **como será a comunicação** (capítulo 11 — papéis, SLA e timeline). A leitura pode ser feita de forma linear para uma compreensão completa, ou por seções, consultando o sumário para acesso direto ao tópico de interesse.

6	6	T+5min	7 dias
Fontes monitoradas em paralelo	Pilares CISEB como taxonomia	SLA alvo dos alertas instantâneos	Cadência da newsletter curada

Princípios de desenho

Cinco princípios orientam todas as decisões arquiteturais detalhadas adiante. Primeiro, **streaming-first**: cada achado percorre o pipeline individualmente, sem esperar por lotes, o que reduz a latência entre coleta e entrega. Segundo, **modularidade por camada**: coletores, normalização, classificação, armazenamento, curadoria e entrega são

componentes independentes, comunicando-se por filas e schemas contratados, permitindo substituir um sem afetar os outros. Terceiro, **idempotência**: todo evento é deduplicado por hash criptográfico, garantindo que reprocessamentos não gerem duplicatas no delivered. Quarto, **observabilidade nativa**: métricas, logs estruturados e tracing estão presentes desde a primeira versão, não como complemento posterior. Quinto, **curadoria humana no circuito crítico**: a IA faz o trabalho pesado, mas nenhum achado é publicado em newsletter sem passar pela revisão do top-N diário — exceto alertas de score máximo, que seguem regra à parte.

Capítulo 2 — Contexto, Justificativa e os 6 Pilares CISEB

O CISEB atua como um centro de inovação educacional cuja oferta pedagógica se organiza em torno de seis pilares tecnológicos e metodológicos complementares. Cada pilar representa não apenas um conjunto de ferramentas, mas uma **filosofia de aprendizagem ativa** que coloca o aluno como protagonista da construção do conhecimento. A edição de 2026 do programa reforçou a ênfase em **Imersões em Trilhas de Aprendizagem** — percursos estruturados que combinam dois ou mais pilares ao longo de semanas, culminando em entregáveis concretos (protótipos, jogos, instalações, projetos de robótica). Compreender o ecossistema de cada pilar — quem produz conhecimento, quem aplica, quem publica — é condição para que o Observatório filtre corretamente o sinal do ruído.

Os seis pilares em detalhe

A **Inteligência Artificial** é aplicada para personalizar o aprendizado, automatizar processos e criar soluções tecnológicas que ajudam a preparar os alunos para os desafios do futuro digital. No CISEB, isso se traduz em trilhas que introduzem conceitos de machine learning, prompts engineering, ética em IA e criação de assistentes educacionais. O Observatório deve capturar tanto ferramentas novas (modelos, SDKs, plataformas de ensino) quanto experiências pedagógicas relatadas por professores em sala de aula, planos de aula abertos e estudos de caso publicados em congressos brasileiros e internacionais.

A **Cultura Maker** fomenta a criação prática, incentivando estudantes e educadores a desenvolverem projetos e soluções com tecnologia e criatividade, promovendo a aprendizagem ativa. Achados relevantes incluem repos em GitHub com projetos de baixo custo, tutoriais de construção de ferramentas didáticas, relatos de feiras maker escolares e metodologias de prototipagem rápida adaptadas ao contexto brasileiro de restrição de recursos.

A **Cultura Digital** explora tecnologias como Realidade Virtual e Realidade Aumentada, oferecendo experiências imersivas que enriquecem o processo de ensino e aprendizagem, conectando o mundo físico ao digital. Aqui o Observatório busca aplicações pedagógicas de RV/RA, plataformas acessíveis (incluindo soluções baseadas em smartphone + cardboard), kits de desenvolvimento e avaliações de impacto cognitivo publicadas em literatura acadêmica.

A integração de **Tecnologia e Arte** permite que alunos e educadores criem jogos, animações e projetos inovadores, desenvolvendo habilidades de pensamento computacional. Este é um pilar particularmente fértil em projetos abertos: Scratch, p5.js, Processing, Godot, GDevelop e pixi.js têm comunidades ativas que publicam tutoriais, plans de aula e jams educacionais. O Observatório deve priorizar recursos replicáveis — ou seja, com código, assets e roteiros disponíveis para download.

A **Fabricação Digital** com uso de ferramentas como impressoras 3D e cortadoras a laser promove a prototipagem, transformando ideias em produtos reais e incentivando a inovação e o empreendedorismo. Achados de valor incluem repositórios de modelos STL pedagógicos (Thingiverse, Printables, Cults), configurações de impressora otimizadas para uso escolar, estudos de segurança em makerspace escolar e cases de fabricação de material didático acessível para alunos com deficiência.

A **Robótica Educacional** oferece um espaço para o aprendizado prático de engenharia, programação e resolução de problemas, utilizando kits modernos de robótica. Os alunos desenvolvem habilidades tecnológicas, criatividade e trabalho em equipe. O Observatório deve monitorar o ecossistema de kits (Arduino, micro:bit, Raspberry Pi Pico, LEGO Spike, Mbot, RoboRemo), competições (OBR, RoboCup Junior, First Lego League), bibliotecas de controle (MicroPython, ROS2 educacional) e relatos de implementação em escolas públicas brasileiras.

A lacuna que o Observatório preenche

Hoje, a descoberta de iniciativas relevantes depende do esforço individual de professores e coordenadores que, esparsamente, navegam portais institucionais, grupos de WhatsApp, canais do YouTube e repositórios acadêmicos. O resultado é desigual: alguns professores reproduzem projetos excelentes, outros reinventam a roda por desconhecerem materiais disponíveis. Há três lacunas concretas que o Observatório endereça. Primeira, **fragmentação**: a informação está espalhada em pelo menos seis famílias de fontes com padrões de publicação distintos. Segunda, **ausência de curadoria pedagógica**: mesmo quando algo é encontrado, falta uma avaliação de aderência aos pilares CISEB e de viabilidade de replicação no contexto do Centro. Terceira, **baixa replicabilidade**: a maior parte do que se publica é notícia institucional sem artefatos reproduzíveis, e o Observatório prioriza justamente o oposto — projetos com código, STLs, planos de aula e tutoriais.

Capítulo 3 — Domínio Semântico: O Que Conta como Achado

Nem tudo que o pipeline coleta constitui um "achado" no sentido usado por este documento. Para que um item seja aceito, enriquecido e eventualmente entregue, ele precisa satisfazer dois critérios: **aderência temática** a pelo menos um dos seis pilares CISEB e **conteúdo substantivo** suficiente para gerar um resumo útil e uma sugestão de aplicação. Itens meramente institucionais (como comunicados administrativos) ou puramente promocionais (como anúncios de cursos pagos sem material aberto) são descartados já na fase de normalização. A tabela a seguir define os sete tipos de achado que o sistema reconhece, com exemplos concretos, pilares típicos e prioridade relativa.

Tipo de Achado	Exemplo Concreto	Pilares Típicos	Replicabilidade	Prioridade
Notícia de projeto	Matéria do portal Porvir sobre escola pública que montou makerspace	Maker, Fabricação Digital	Baixa (relato)	Média
Repositório de código	Repo GitHub com jogo educacional em p5.js sobre frações	Tecnologia e Arte, IA	Alta (código aberto)	Alta
Plano de aula aberto	PDF no site da OBI com sequência didática de 4 aulas usando micro:bit	Robótica, IA	Alta (roteiro completo)	Alta
Modelo 3D / STL	STL no Printables de braço robótico impresso para ensino de cinemática	Fabricação Digital, Robótica	Alta (arte-fato)	Alta
Paper acadêmico	Artigo SciELO sobre uso de RV no ensino de biologia celular	Cultura Digital	Média (metodologia)	Média
Edital / oportunidade	Chamada FAPESP de apoio a projetos de IA na educação básica	IA (transversal)	N/A (oportunidade)	Crítica
Evento / chamada	Inscrições abertas para a OBR 2026 — regional São Paulo	Robótica	N/A (evento)	Alta

Tabela 3.1 — Tipos de achado reconhecidos pelo Observatório CISEB.

A coluna **replicabilidade** merece destaque porque ela é o principal filtro de qualidade do sistema: achados com artefatos reproduzíveis (código, STL, plano de aula, dataset) recebem um bônus significativo no scoring descrito no capítulo 7. Achados puramente descritivos (notícias, releases institucionais) são mantidos no acervo mas raramente

chegam aos canais de entrega, a menos que traguem uma ideia metodológica particularmente transferível. Essa escolha reflete a prioridade do CISEB por **projetos práticos vindos de metodologias ativas**, conforme definição do próprio programa — criação de professores, alunos ou ambos.

Capítulo 4 — Visão Arquitetural Macro

A arquitetura do Observatório segue um padrão de **pipeline em camadas** com fluxo unidirecional: cada camada consome a saída da anterior e produz uma saída normalizada para a próxima. Não há chamadas reversas entre camadas durante o fluxo normal — feedback loops (como a recalibração mensal do classificador) acontecem fora do caminho crítico, em jobs batch agendados. Essa restrição simplifica a resiliência: se a camada de curadoria fica indisponível, a camada de armazenamento continua recebendo e indexando achados; quando a curadoria volta, ela processa o backlog sem perda. O diagrama a seguir apresenta as seis camadas e os dois canais de entrega.




Figura 4.1 — Arquitetura macro do Observatório CISEB, das seis fontes aos dois canais de entrega.

Princípios arquiteturais

A escolha por **streaming-first** em vez de batch noturno responde à necessidade de alertas em tempo real para achados críticos (editais, eventos com prazo curto). Cada coletor publica eventos individuais em uma fila Redis Streams assim que detecta

novidade, e o processamento semântico (LLM + embeddings) consome esses eventos em paralelo. A latência ponta-a-ponta alvo é de cinco minutos entre a publicação da fonte original e o disparo do alerta, em condições normais de operação.

A **modularidade por camada** permite que o time substitua componentes sem rewirar todo o sistema. Por exemplo: a camada de enriquecimento pode mudar de GLM-4 para Claude ou para um modelo local sem que coletores ou entrega precisem ser tocados — basta respeitar o schema JSON de entrada e saída da camada. Da mesma forma, novos coletores podem ser adicionados sem modificar o restante do pipeline, desde que publiquem no formato de evento contratado.

A **idempotência** é garantida por hash SHA-256 do conteúdo normalizado de cada item (título + corpo canônico + URL). Antes de um coletor publicar um evento, ele consulta um índice de hashes recentes no Redis; se o hash já existe, o evento é descartado silenciosamente. Esse mecanismo tolera reprocessamentos, re-execuções de cron e até rededloys sem gerar duplicatas na entrega — problema clássico de sistemas de monitoramento menos cuidadosos.

A **observabilidade nativa** é implementada com Prometheus (métricas), Loki (logs estruturados) e Grafana (dashboards), todos containers no mesmo docker-compose do MVP. Cada camada expõe métricas de吞吐 (throughput), latência por estágio, taxa de erro e tamanho de fila. Alertas operacionais (não confundir com alertas de achados) são disparados para o mesmo canal Telegram usado pela entrega, mas com prefixo [OPS] para distinguir.

Capítulo 5 — Camada de Coletores: As 6 Fontes

A camada de coletores é a única que conversa com o mundo exterior. Cada coletor é um processo independente, responsável por uma família de fontes, com seu próprio cronograma, tratamento de erros e mecanismo de checkpoint. A escolha por separar coletores por família — e não por fonte individual — reduz a complexidade operacional: o coletor de "literatura acadêmica" abstrai as particularidades de Google Scholar, SciELO, CAPES e arXiv por trás de uma interface comum. A tabela a seguir resume as seis famílias, com a stack sugerida para cada uma, frequência de coleta, tipo de dado predominante e principais desafios técnicos.

Fonte	Ferramenta / API	Frequência	Tipo de Dado	Desafio Técnico
Web / Blogs	Scrapy + feedparser + trafilatura; RSS/Atom; Common Crawl index	15-30 min	HTML, artigos, posts	Boilerplate removal; sites sem RSS; rate-limit

Fonte	Ferramenta / API	Frequência	Tipo de Dado	Desafio Técnico
GitHub	GitHub GraphQL API + PyGithub; tópicos: education, maker, robotics	30 min	Repositórios, READMEs, releases	Rate-limit 5k req/h; distinguir edu de hobby
Fóruns / Comunidades	Reddit API (PRAW); bridges Telegram/WhatsApp; Stack Exchange API	10-20 min	Threads, comentários, links	ToS de WhatsApp; comunidades privadas; ruído
Redes Sociais	YouTube Data API v3; LinkedIn scraping limitado; hashtags IG via API Graph	30-60 min	Vídeos, posts, descrições	APIs pagas; shadow-banning; metadados escassos
Literatura Acadêmica	scholarly (Google Scholar); SciELO OAI-PMH; CAPES; arXiv API	Diária	PDFs, abstracts, metadados	Captcha do Scholar; PDFs pesados; paywall
Eventos / Editais	Scrapy em sites MEC/FAPESP/CAPES; newsletters institucionais	Diária + gatilho	Editais, chamadas, inscrições	Datas críticas; formatos heterogêneos

Tabela 5.1 — As seis famílias de fontes monitoradas pelo Observatório.

Considerações sobre ToS e ética de coleta

Toda coleta respeita os Termos de Serviço das plataformas e os arquivos robots.txt dos sites. Para APIs pagas ou com rate-limit restritivo (YouTube, LinkedIn), priorizamos acesso via APIs oficiais com quotas documentadas; quando insuficiente, recorreremos a scraping respeitoso (com User-Agent identificável, delays entre requisições e cache local agressivo). WhatsApp e Telegram são acessados via bots em grupos onde o CISEB tenha participação explícita — nunca por scraping de grupos públicos sem autorização. Os detalhes de governança estão no capítulo 14.

Capítulo 6 — Ingestão, Fila e Normalização

A camada de ingestão recebe eventos publicados pelos coletores e os prepara para o processamento semântico. A escolha de **Redis Streams** como fila em vez de Kafka ou RabbitMQ é deliberada para o MVP: Redis é mais leve de operar, tem latência submilissegundo para nosso volume (estimado em 1k-5k eventos/dia), e oferece grupos de consumidores nativos para paralelismo. A migração para Kafka fica reservada para a Fase 4 (scale), se o volume cruzar 50k eventos/dia — patamar em que Redis começa a perder vantagem.

Schema de evento

Todo evento publicado na fila segue o mesmo schema JSON canônico. A obrigatoriedade de campos é o contrato entre coletores e processadores:

```
{
  "event_id": "uuid v4",
  "source": "github" | "web" | "scielo" | ...,
  "source_url": "https://...",
  "collected_at": "2026-06-25T10:30:00Z",
  "content_hash": "sha256(...)",
  "raw_payload": { ... fonte-específico ... },
  "raw_text": "texto extraído do conteúdo",
  "language": "pt" | "en" | "es",
  "metadata": { ... metadados estruturados ... }
}
```

Deduplicação e normalização

A deduplicação ocorre em duas fases. A primeira, **sintática**, é feita pelo hash SHA-256 do campo `content_hash`, que combina URL canonicalizada + título normalizado + corpo sem whitespace. Se dois coletores publicam o mesmo item (por exemplo, um post que aparece tanto no RSS quanto no scraper HTML), apenas o primeiro evento é aceito; o segundo é descartado e logado. A segunda fase, **semântica**, é feita após enriquecimento LLM: se dois achados têm embeddings com similaridade cosseno acima de 0,93, o de maior score é mantido e o outro é marcado como duplicata semântica e arquivado.

A normalização converte o payload cru em um formato canônico: extração de texto principal com trafilatura (que lida bem com boilerplate), limpeza de caracteres invisíveis, identificação de idioma com langdetect, corte para um máximo de 5.000 tokens (preservando o início e o fim do texto, que concentram a maior densidade informacional) e geração de um snippet de 200 caracteres. O resultado é o que a próxima camada consome.

Capítulo 7 — Classificação por Pilar CISEB e Scoring de Relevância

Esta é a camada que diferencia o Observatório de um mero agregador de RSS. Ela atribui a cada achado: (a) um ou mais **pilares CISEB** (classificação multi-rótulo), (b) um conjunto de **atributos enriquecidos** (público-alvo, geografia, recursos citados, nível educacional, replicabilidade) e (c) um **score composto** de 0 a 100 que determina o roteamento. A combinação desses três elementos permite que a próxima camada (curadoria) decida com baixa ambiguidade o que fazer com cada item.

Classificador multi-rótulo por pilar

Um achado pode tocar múltiplos pilares simultaneamente — um repositório de robótica educacional com interface web em p5.js que usa um modelo de IA para visão computacional toca três pilares (Robótica, Tecnologia e Arte, IA). O classificador opera em duas etapas. Primeiro, computa embeddings do conteúdo normalizado e calcula a similaridade cosseno contra descrições canônicas dos seis pilares (previamente embedadas). Segundo, submete o top-3 candidatos a um LLM (GLM-4) com prompt few-shot que retorna, para cada pilar, uma confiança entre 0 e 1. Pilares com confiança $\geq 0,55$ são aceitos; abaixo disso são descartados. Esse desenho híbrido (embeddings + LLM) combina velocidade (embeddings são baratos) com precisão (LLM resolve casos ambíguos).

Fórmula de scoring composto

O score composto combina cinco dimensões, cada uma normalizada para 0-100 antes de ser ponderada. A fórmula reflete explicitamente as prioridades definidas pelo CISEB no briefing original — Brasil/Lusofonia, replicabilidade, projetos práticos e nível educacional são fatores de primeira classe, não apenas filtros binários.

Dimensão	Peso	Como é Calculado	Justificativa
Alinhamento ao pilar	30%	Média das confianças do classificador multi-rótulo	Pilar é a unidade organizacional do CISEB
Brasil / Lusofonia	20%	Heurística: idioma pt, domínio .br, menção a estados/cidades, autor brasileiro	Prioridade explícita do briefing
Replicabilidade	20%	Presença de artefatos: código, STL, plano de aula, dataset, tutorial	Filtro de qualidade central do sistema
Projeto prático	15%	LLM detecta: é criação de professor/aluno? Tem implementação?	Briefing: "não apenas notícias"
Nível educacional	10%	Classificação: básica, técnico, superior, form. continuada	Permite filtrar por público
Novidade temporal	5%	Decaimento exponencial: 100 se $\leq 7d$; 80 se $\leq 30d$; 50 se $\leq 90d$; 30 caso contrário	Recompensa achados recentes

Tabela 7.1 — Pesos e cálculo do score composto (0-100).

Thresholds de roteamento

O score composto determina o destino do achado em regras claras e auditáveis. Achados com **score** ≥ 75 disparam alerta instantâneo via Telegram/WhatsApp imediatamente após a revisão humana do top-N diário (ver capítulo 9). Achados com **score 50-74** entram na fila de candidatos à newsletter semanal. Achados com **score 30-49** são arquivados e ficam acessíveis via busca no dashboard, mas não chegam aos canais push. Achados com **score** < 30 são descartados do índice ativo após 7 dias, mantendo apenas metadados para

fins de auditoria. Os thresholds são parâmetros de configuração e podem ser ajustados mensalmente com base no feedback dos revisores humanos.

Capítulo 8 — Armazenamento e Busca Semântica

O armazenamento central é um **PostgreSQL 16** com a extensão **pgvector** para índice de embeddings. A escolha por Postgres em vez de um banco orientado a documentos (MongoDB) ou um search engine dedicado (Elasticsearch) é pragmática: Postgres cobre os três requisitos do sistema — armazenamento relacional metadados, busca textual full-text (TSVECTOR) e busca vetorial (pgvector) — em um único processo operável, reduzindo a superfície de manutenção no MVP. Para volumes acima de 1 milhão de achados, uma migração para Elasticsearch como camada de busca secundária pode ser avaliada na Fase 4.

Esquema principal

O esquema é deliberadamente simples, com seis tabelas principais:

```
findings (id, source, url, title, content_text, snippet, language,
          collected_at, content_hash, embedding vector(768), status)
sources (id, name, type, last_polled_at, healthy)
pillars (id, slug, name, description, canonical_embedding vector(768))
scores (finding_id, pillar_id, confidence, score_composite,
        dim_alignment, dim_br_luso, dim_replicable, dim_practical,
        dim_level, dim_novelty, computed_at)
reviews (finding_id, reviewer_id, decision, edited_summary,
         feedback_tags, reviewed_at)
deliveries (finding_id, channel, sent_at, opened_at)
```

Índices e estratégia de busca

Três índices cobrem os padrões de acesso esperados. Um **GIN** sobre metadados JSONB permite filtrar por atributos como nível educacional ou geografia com latência submilissegundo. Um **IVFFlat** sobre a coluna embedding dos findings habilita busca por similaridade vetorial (k-NN) com bom trade-off entre precisão e velocidade. Um **TSVECTOR** sobre título + snippet habilita busca full-text tradicional. A combinação de busca BM25 (TSVECTOR) com busca vetorial (pgvector) é chamada de **busca híbrida** e é o padrão para queries complexas no dashboard: o usuário pode, por exemplo, buscar "robótica microbit escola pública" e receber resultados que combinam matching textual com similaridade semântica ao conceito.

A política de retenção é **24 meses quente** no Postgres, com migração para **arquivo frio em S3** (ou equivalente on-prem) após esse período. Achados descartados pelo scoring

(score < 30) têm seus textos removidos após 7 dias, mas mantêm metadados por 12 meses para fins de auditoria do próprio sistema. Essa política equilibra custo de armazenamento (texto é o maior consumidor de espaço) com a necessidade de rastreabilidade.

Capítulo 9 — Curadoria IA + Revisão Humana

A camada de curadoria é onde o sistema deixa de ser puramente automático e incorpora o julgamento humano no circuito crítico. O modelo operacional escolhido é o que chamamos de **IA full + revisão**: a IA faz todo o trabalho pesado (classificação, scoring, ranking, geração de resumo, sugestão de aplicação), e um revisor humano aprova, edita ou rejeita o top-N diário antes que qualquer item chegue à newsletter. Alertas instantâneos (score ≥ 75) seguem regra à parte: são enviados imediatamente, mas o revisor recebe notificação simultânea e pode cancelar/recuperar a publicação em até 5 minutos se julgar inadequada.

Pipeline de curadoria

O pipeline de curadoria consiste em seis etapas sequenciais, executadas sobre cada novo achado ou em batch diário para o top-N:

- 1 **Dedup final**: remove duplicatas semânticas detectadas por similaridade de embeddings.
- 2 **Classificação**: atribui pilares CISEB via embeddings + LLM few-shot.
- 3 **Scoring**: calcula score composto 0-100 com a fórmula do capítulo 7.
- 4 **Ranking**: ordena achados do dia por score composto.
- 5 **Geração de card**: LLM produz título editado, resumo executivo (2-3 linhas) e "como aplicar no CISEB".
- 6 **Fila de revisão**: top-N diário (default: top 10 score ≥ 75) é enviado para a interface do revisor humano.

Interface de revisão

A interface de revisão é uma aplicação web leve (Next.js ou Streamlit) que apresenta cada candidato como um **card** contendo: título editado pela IA, pilar(es) atribuído(s) com confiança, score composto com breakdown das cinco dimensões, resumo executivo, sugestão de aplicação no CISEB, link original, screenshot automática da página (quando aplicável) e três botões: **Aprovar**, **Editar** (abre formulário para corrigir título, resumo, pilar, aplicação) e **Rejeitar** (com tags de feedback: "off-topic", "duplicata", "baixa qualidade", "fora de escopo pedagógico"). O revisor pode processar o top-N diário em 10-15 minutos.

Feedback loop e recalibração

Toda decisão do revisor (aprovar, editar, rejeitar com tag) é registrada na tabela reviews e alimenta dois processos mensais de recalibração. O primeiro recalibra o **classificador de pilares**: o conjunto de achados revisados vira dataset de fine-tuning (ou few-shot enrichment) para o próximo mês. O segundo recalibra os **pesos do scoring**: se, por exemplo, o revisor rejeita sistematicamente achados com alta novidade temporal mas baixa replicabilidade, o peso da replicabilidade pode ser aumentado em 5 pontos e o da novidade reduzido em 5. Esse loop é a garantia de que o sistema aprende com a equipe em vez de petrificar as suposições iniciais.

Capítulo 10 — Camada de Entrega: Newsletter e Alertas

A entrega é o que torna o Observatório útil no dia a dia do CISEB. Foram escolhidos dois canais complementares, com características opostas: **alertas instantâneos** via Telegram e WhatsApp para achados críticos (baixa latência, baixo volume, alta urgência) e uma **newsletter semanal** em PDF e HTML para o acompanhamento consolidado (alta latência, alto volume, baixa urgência). Um terceiro canal opcional — um dashboard web leve — pode ser adicionado na Fase 3 para consultas ad-hoc.

Alertas instantâneos

Os alertas são disparados para um canal Telegram e um grupo WhatsApp dedicados do CISEB. O formato do alerta é um **card visual** com cinco elementos: (1) título editado (máximo 80 caracteres), (2) pilar CISEB principal como tag colorida, (3) link original com preview, (4) resumo executivo de 2 linhas, (5) sugestão de aplicação no CISEB em 1 linha precedida do rótulo "Aplicação sugerida". O disparo é feito por um bot via python-telegram-bot e whatsapp-web.js (este último requer um número de WhatsApp Business dedicado). O SLA alvo é de 5 minutos entre a coleta e o disparo do alerta. Alertas podem ser cancelados pelo revisor humano em até 5 minutos após o disparo, com uma mensagem de retratação automática no mesmo canal.

Newsletter semanal

A newsletter é gerada toda segunda-feira às 7h e enviada via **Postmark** ou **Amazon SES** para uma lista gerida pelo CISEB. Ela contém entre 20 e 30 achados selecionados (top score da semana após revisão humana), organizados por pilar CISEB, com a seguinte estrutura por item: título, pilar, score, resumo de 3-4 linhas, "como aplicar no CISEB" em 2 linhas, e link original. A newsletter é gerada em dois formatos: HTML responsivo (para leitura em email clients) e PDF anexo (para arquivo e consulta offline). A geração do PDF reutiliza o mesmo motor ReportLab + paleta do presente documento, garantindo

identidade visual consistente entre o esqueleto arquitetural e as publicações operacionais do Observatório.

Dashboard web (opcional, Fase 3)

Um dashboard Next.js leve pode ser adicionado a partir da Fase 3. Ele oferece: busca híbrida (textual + semântica) sobre o acervo, filtros por pilar / período / nível educacional / fonte, favoritos pessoais, exportação para BibTeX/CSV, e um modo "explorar" que recomenda achados similares a um item selecionado. O dashboard não substitui os canais push — é complementar para consultas deliberadas. A audiência natural são professores que queiram pesquisar materiais antes de uma aula.

Capítulo 11 — Fluxo de Comunicação, Papéis e SLA

A clareza sobre papéis e SLAs é o que evita que o Observatório se torne um sistema técnico correto mas operacionalmente inútil. Quatro papéis orbitam o sistema, cada um com responsabilidade distinta: o **Orquestrador** define prioridades, fonte de prioridades e SLAs; o **Arquiteto** mantém o pipeline saudável e evolui componentes; o **Curador IA** é o autômato que executa o trabalho pesado de classificação, scoring e geração de cards; o **Revisor Humano** aprova, edita ou rejeita o top-N diário. A figura a seguir mostra a timeline de um achado atravessando essas quatro responsabilidades, do momento da coleta até a entrega final.




Figura 11.1 — Timeline de um achado, dos 4 papéis aos 2 canais de entrega.

Tabela de SLAs

Etapa / Canal	SLA Alvo	Janela de Operação	Responsável
Coleta de fonte	15-60 min (por fonte)	24/7 automático	Coletores (autômato)

Etapa / Canal	SLA Alvo	Janela de Operação	Responsável
Classificação + score	T+3 min após coleta	24/7 automático	Curador IA
Alerta para score ≥ 75	T+5 min após coleta	24/7 (com notificação ao revisor)	Curador IA
Revisão humana do top-N	30 min após card gerado	Dia útil, 9h-19h	Revisor Humano
Newsletter semanal	Segundas 7h-8h	Automático após revisão	Curador IA + Orquestrador
Recalibração do modelo	Mensal, primeira semana	Janela de manutenção	Arquiteto + Revisor
Recuperação de falha	15 min para detectar; 1h para restaurar	24/7 monitorado	Arquiteto

Tabela 11.1 — SLAs operacionais por etapa do pipeline.

Tratamento de exceções

A operação normal é desenhada para ser silenciosa: o revisor humano interage apenas com o top-N diário e o Orquestrador recebe apenas o digest semanal mais alertas operacionais. As exceções seguem três caminhos. Primeiro, **falhas de coletor**: se um coletor falha três vezes consecutivas, um alerta [OPS] é disparado no Telegram para o Arquiteto, que tem 1h para restaurar. Segundo, **explosão de volume**: se a fila excede 1.000 eventos pendentes, o sistema ativa processamento paralelo adicional e notifica o Arquiteto. Terceiro, **degradação de qualidade da IA**: se a taxa de aprovação do revisor cai abaixo de 60% por duas semanas consecutivas, o Arquiteto inicia uma recalibração extraordinária do classificador. Nenhum desses caminhos exige intervenção do Orquestrador no dia a dia — apenas comunicação estruturada.

Capítulo 12 — Stack Tecnológica Sugerida

A stack abaixo é uma **recomendação de partida**, não um contrato. Foi montada priorizando três critérios: (a) **operabilidade por equipe pequena** (preferência por tecnologias conhecidas e com boa documentação em português), (b) **custo baixo no MVP** (preferência por open-source e serviços com free tier generoso), e (c) **caminho de saída claro** (cada componente tem uma alternativa identificada para a fase de scale). Substituições são esperadas e bem-vindas conforme a equipe amadurece e os volumes crescem.

Cama da	Componente	Ferramenta Sugerida	Justificativa / Alternativa
Coleta	Web scraper	Scrapy 2.11+	Maduro, escalável; alt: Playwright para JS-heavy
Coleta	RSS/Atom	feedparser	Padrão de facto Python
Coleta	Extração de texto	trafilatura	Melhor boilerplate removal para PT-BR
Coleta	GitHub	PyGithub + GraphQL	API oficial; alt: gh CLI para ad-hoc
Coleta	YouTube	youtube-transcript-api	Acesso a transcrições (ricas em conteúdo)
Coleta	Acadêmico	scholarly + arxiv API	Alt: Semantic Scholar API (gratuita)
Fila	Message broker	Redis Streams	Leve; alt Fase 4: Kafka
Proces so	Workers	Celery 5 + Redis broker	Padrão Python; alt: Dramatiq
IA	LLM (classif+re sumo)	GLM-4 via z-ai-web-dev-sdk	Custo/qualidade; alt: Claude Haiku, Llama 3.1 70B local
IA	Embeddings	sentence-transformers (BGE-M3)	Multilíngue (PT+EN+ES); alt: OpenAI text-embedding-3
Armaz.	Banco relaciona l	PostgreSQL 16 + pgvector	Único processo cobre 3 requisitos
Armaz.	Arquivo frio	MinIO (S3-compatible on-prem)	Alt: AWS S3, Cloudflare R2
Entreg a	E-mail	Amazon SES	Custo baixo; alt: Postmark (melhor deliverability)
Entreg a	Telegram bot	python-telegram-bot	API oficial estável
Entreg a	WhatsApp	whatsapp-web.js (Node)	Requer número Business; alt: API oficial Meta
Obs.	Métricas/logs	Prometheus + Loki + Grafana	Stack CNCF padrão; alt: Datadog pago
Infra	Orquestração	Docker Compose (MVP) → k8s (Fase 4)	Progressão natural de complexidade

Tabela 12.1 — Stack tecnológica sugerida por camada.

Capítulo 13 — Roadmap de Implementação

O roadmap é organizado em cinco fases sequenciais, com duração total estimada de 20 semanas (5 meses) até a operação em cobertura completa, mais uma fase contínua de scale e evolução. Cada fase tem um critério de saída objetivo — não se avança para a próxima fase sem atender o critério, evitando acúmulo de débito técnico. A fase 0 é de decisão e setup, sem código de produção; a fase 4 é operação contínua com melhorias incrementais.

Fase	Objetivo	Entregáveis Principais	Duração	Critério de Saída
0 — Decisão e Setup	Alinhar decisões pendentes (cap. 16) e provisionar infra	Conta cloud; repositório Git; docker-compose base; lista de revisor humano	2 sem	Decisões do cap. 16 fechadas; ambiente roda "hello world"
1 — MVP	Provar o circuito ponta-a-ponta com 1 fonte e 1 pilar	Coletor GitHub + normalização + classificador 1 pilar + alerta Telegram	4 sem	5+ alertas reais enviados e revisados em uma semana
2 — Piloto	Expandir para 3 fontes e 3 pilares; ativar newsletter	+ coletores Web e Acadêmico; + pilares Maker, Robótica, IA; newsletter HTML semanal	6 sem	Newsletter enviada por 4 semanas seguidas; taxa de aprovação $\geq$ 70%
3 — Cobertura Completa	6 fontes + 6 pilares + dashboard opcional	+ Fóruns, Redes Sociais, Eventos; + pilares restantes; dashboard Next.js	8 sem	Cobertura 6/6 pilares; dashboard com busca híbrida funcional
4 — Scale e Evolução	Operação contínua; observabilidade; multicanal; feedback loop	Migração para k8s (se vol > 50k/dia); recalibração mensal automatizada; métricas de impacto	Contínuo	KPIs do cap. 15 medidos mensalmente; roadmap trimestral

Tabela 13.1 — Roadmap de implementação em cinco fases.

A duração de cada fase inclui uma margem de 20% para imprevistos — padrão razoável para projetos com componentes de IA cujo comportamento em produção é parcialmente imprevisível. Fases paralelas (por exemplo, começar o dashboard na Fase 2) são possíveis se a equipe tiver capacidade, mas não devem comprometer o caminho crítico do pipeline principal. A recomendação é manter foco linear até a Fase 3 e só depois paralelizar evoluções.

Capítulo 14 — Governança, Ética e Riscos

Todo sistema que coleta, classifica e republica informação de terceiros carrega riscos éticos e legais que precisam ser endereçados explicitamente, não varridos para baixo do tapete. Este capítulo identifica os cinco riscos mais relevantes para o Observatório CISEB, com probabilidade, impacto e mitigação concreta. A regra ética fundamental do sistema é simples: **sempre citar a fonte original, nunca republicar conteúdo integral, optar por links + resumos curtos**. Respeitar essa regra resolve a maior parte dos riscos jurídicos e mantém a relação saudável com a comunidade educacional que produz o conteúdo que o Observatório curadoria.

Risco	Probabilidade	Impacto	Mitigação
Viés do LLM na classificação de pilares	Média	Médio	Few-shot com exemplos revisados; recalibração mensal; auditoria de paridade por pilar
Direitos autorais de materiais replicados	Alta	Alto	Republicar apenas resumos + links; nunca o conteúdo integral; respeitar licenças (CC BY, MIT, etc.)
LGPD (dados pessoais de educadores)	Média	Alto	Não coletar dados pessoais além do necessário; anonimizar em estatísticas; DPO consultado na Fase 0
ToS de redes sociais (risco de banimento)	Média	Médio	Preferir APIs oficiais; respeitar rate-limits; User-Agent identificável; fallback para fontes alternativas
Degradação de qualidade por auto-loop	Baixa	Médio	Revisão humana obrigatória no top-N; alertas de taxa de aprovação; refresh periódico do conjunto de few-shot

Tabela 14.1 — Riscos identificados e mitigações.

Princípios éticos operacionais

Cinco princípios éticos orientam decisões operacionais do dia a dia. Primeiro, **transparência de curadoria**: todo achado entregue tem link para a fonte original e atribuição clara ao autor, sem exceção. Segundo, **não republicação integral**: resumos são sempre produções originais do LLM sob revisão humana, com extensão máxima de 4 linhas; o leitor interessado deve clicar no link para o conteúdo completo. Terceiro, **diversidade de fontes**: o sistema monitora ativamente se algum pilar está sendo coberto majoritariamente por uma única fonte e gera alerta se isso ocorrer, evitando captura editorial. Quarto, **direito ao esquecimento**: qualquer autor pode solicitar a remoção de seus conteúdos do acervo do Observatório, com prazo de 7 dias para atendimento. Quinto, **auditoria aberta**: métricas agregadas (volume por fonte, taxa de aprovação, cobertura por pilar) são publicadas mensalmente em um relatório de transparência acessível a toda equipe CISEB.

Capítulo 15 — Métricas de Sucesso (KPIs)

KPIs traduzem a intenção do Observatório em números verificáveis e permitem que a equipe avalie, mês a mês, se o sistema está entregando valor. Os oito KPIs abaixo estão organizados em três grupos — **cobertura** (o sistema está vendo o ecossistema?), **qualidade** (o que chega ao usuário é relevante?) e **impacto** (o que chega ao usuário muda a prática pedagógica?). Os dois primeiros grupos são medidos automaticamente; o terceiro requer pesquisa qualitativa trimestral com a equipe do CISEB.

KPI	Grupo	Definição Operacional	Meta	Frequência
Fontes ativas	Cobertura	Coletores saudáveis / total configurado	$\geq 90\%$	Diária
Achados por dia	Cobertura	Média móvel 7d de eventos únicos coletados	50-500/dia	Diária
Cobertura por pilar	Cobertura	Pilares com ≥ 5 achados/dia na média semanal	6 de 6	Semanal
Precisão da curadoria	Qualidade	Achados aprovados / achados no top-N revisado	$\geq 75\%$	Semanal
Recall estimado	Qualidade	Achados relevantes capturados / amostra manual	$\geq 80\%$	Mensal
Taxa de falso positivo	Qualidade	Alertas cancelados pelo revisor / alertas enviados	$\leq 10\%$	Semanal
Taxa de abertura (newsletter)	Impacto	Opens únicos / entregas	$\geq 45\%$	Semanal
Achados replicados no CISEB	Impacto	Achados citados em relatórios pedagógicos trimestrais	≥ 3 /trimestre	Trimestral

Tabela 15.1 — KPIs do Observatório CISEB, com metas e frequência de medição.

Os KPIs de impacto são os mais difíceis de medir mas os mais importantes para justificar a continuidade do sistema. "Achados replicados no CISEB" exige que a equipe pedagógica cite explicitamente, em relatórios trimestrais de atividades, quais projetos ou materiais foram inspirados por achados do Observatório. Esse dado pode ser coletado por meio de um campo estruturado no relatório ("Origem: Observatório CISEB, achado de DD/MM") e alimenta de volta o sistema, permitindo fechar o loop entre descoberta e aplicação. A meta inicial de três replicações por trimestre é deliberadamente modesta — o objetivo no primeiro ano é estabelecer o hábito de citar a fonte; a meta pode ser revista para cima a partir do segundo ano.

Capítulo 16 — Próximos Passos e Decisões Pendentes

Este documento entrega um esqueleto arquitetural completo, mas o início da implementação depende de oito decisões que precisam ser tomadas pelo CISEB antes da Fase 0 terminar. Cada decisão tem uma pergunta-guia e um prazo sugerido dentro das 2 semanas da Fase 0. As respostas determinam configurações, custos e escolhas de stack que só fazem sentido serem ajustadas uma vez — refazer depois é caro. A recomendação é que o Orquestrador convoque uma reunião de kickoff com o Arquiteto e o futuro Revisor Humano para fechar todas as oito em uma única sessão estruturada de 90 minutos.

- 1 Orçamento de LLM (decisão financeira).** Qual teto mensal de gasto com chamadas de LLM (GLM-4, Claude, etc.) o CISEB consegue absorver? Estimativa inicial: US\$ 50-150/mês para volume MVP. Prazo: semana 1 da Fase 0.
- 2 Revisor Humano (papel operacional).** Quem da equipe do CISEB assumirá a revisão diária do top-N (10-15 min/dia)? É um professor? Um coordenador? Rotativo? Definir antes de iniciar. Prazo: semana 1.
- 3 Canais Telegram e WhatsApp (infraestrutura de entrega).** Qual número de WhatsApp Business será usado? Qual canal/grupo Telegram receberá os alertas? Quem é admin? Prazo: semana 1.
- 4 Hospedagem (cloud vs on-prem).** O sistema roda em cloud (AWS, GCP, Cloudflare) ou on-prem CISEB? Para volumes MVP, cloud custa US\$ 30-80/mês; on-prem exige uma máquina com 16GB RAM. Prazo: semana 2.
- 5 Lista inicial de fontes prioritárias (escopo Fase 1-2).** Dentre as 6 famílias, quais fontes específicas são absolutamente prioritárias no contexto do CISEB? (Ex.: Porvir, Nova Escola, OBR, Printables, github.com/topics/educational-robotics). Prazo: semana 2.
- 6 Política de retenção (conformidade).** Confirmar 24 meses quente + S3 frio, ou ajustar? Há requisitos legais do CISEB ou da instituição mantenedora que mudam esses números? Prazo: semana 2.
- 7 Frequência da newsletter (cadência editorial).** Semanal (segundas 7h) é o padrão sugerido. Quinzenal reduz volume mas perde oportunidade. Diária é inviável sem expandir o time editorial. Prazo: semana 2.
- 8 Definição operacional de "replicável" (critério de qualidade).** O que conta como replicável para o CISEB? Apenas código aberto? Inclui planos de aula em PDF? Vídeos tutoriais? Definir para calibrar o scorer. Prazo: semana 2.

Com as oito decisões fechadas e a Fase 0 concluída, o Observatório CISEB está pronto para entrar na Fase 1 (MVP) e começar a provar o circuito ponta-a-ponta em quatro semanas. A partir da primeira newsletter enviada e dos primeiros alertas reais revisados,

o sistema entra em regime de melhoria contínua orientado pelos KPIs do capítulo 15 e pelo feedback estruturado do Revisor Humano, que mensalmente realimenta o classificador e o scorer. O esqueleto aqui proposto não é um fim em si mesmo — é o ponto de partida para um Observatório que amadurece junto com a prática pedagógica CISEB.